


1 Grundlagen

- Grundlagen
 - $Y = f(x) + \epsilon$
 - Y = Zielgröße, $f()$ = unbekanntes/wahres Modell, X = Prädiktoren, ϵ Nicht reduzierbarer Fehler
 - $\hat{Y} = \hat{f}(X) + \epsilon$
 - \hat{Y} = Schätzung der Zielgröße, \hat{f} = Schätzung des Modells
 - Ziel: Möglichst genaue Schätzung finden
- Ziel:
 - Prediction (Vorhersage von Werten)
 - Inference (Ursachenanalyse, wie wirken sich Änderungen aus)
- Bias-Variance Tradeoff
 - Bias: Fehler des Modells durch falsche Annahmen der Realität
 - Variance: Fähigkeit des Modells auf anderen Subsets gleich gute Modelle zu erzeugen bzw. Fehleranfälligkeit bei Änderungen in Trainingsdaten
 - TrainingsError: Wird immer kleiner, da Modell sich immer besser anpasst
 - TestError: Wird erst kleiner, steigt dann aber wieder (Overfitting)
 - Nichtreduzierbarer Error: Bleibt immer gleich (Messfehler etc.)



2 Regression

- Modellgüte:
 - Schätzung der Parameter β_0 und β_1 über kleinste Quadrate
 - $\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) * (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$
 - $\beta_0 = \bar{y} - \beta_1 \bar{x}$
 - Erwartungstreue: $E(\hat{\beta}_0) = \beta_0$ und $E(\hat{\beta}_1) = \beta_1$
 - $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$
 - $RSE = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$ (Zielgröße weicht im Durchschnitt RSE Einheiten von der Regressionsgeraden ab)

- $R^2 = 1 - \frac{RSS}{TSS}$, je größer desto besser $0 \leq R^2 \leq 1$ (Var(Zielwert) wird durch $R^2\%$ der Prädiktoren erklärt)
- $R^2_{adj} = 1 - \frac{(1-R^2)(N-1)}{N-p-1}$ Adjustiert mit Anzahl der Prädiktoren
- Standardfehler und Intervalle
 - $Var(\epsilon) = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
 - $(SE(\hat{\beta}_0))^2 = Var(\epsilon) * (\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2})$
 - $(SE(\hat{\beta}_1))^2 = \frac{Var(\epsilon)}{\sum_{i=1}^n (x_i - \bar{x})^2}$
 - Intervallschätzung: $[\hat{\beta}_1 - 2 * SE(\hat{\beta}_1), \hat{\beta}_1 + 2 * SE(\hat{\beta}_1)]$
 - Interpret: Aus 100 Proben liegt β_1 in 95 Fällen im Intervall
 - 95%-Konfidenzintervall: bezieht sich auf den durchschnittlichen Y Wert
 - 95%-Prognoseintervall: bezieht sich auf den konkreten Wert Y von Ausgangswerten $X_1 \dots$
- t-Test
 - $H_0 : \beta_0 = 0; H_1 : \beta_1 \neq 0$
 - X_1 Hat keinen Einfluss auf Y
 - $t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$
 - Einfach den p-Wert ablesen, wenn < als bspw. 0.05 dann H_0 verwerfen
- F-Test
 - $H_0 : \beta_0 = \beta_1 = \dots = 0$
 - Alle Prädiktoren haben keinen Einfluss auf Y
- Qualitative Prädiktoren:
 - Prädiktoren mit 2 Ausprägungen:**
 - DummyVariable aka 0(No) oder 1 (Yes)
 - Achte auf Normalausprägung von R**
 - $\hat{y} = \beta_0 + \beta_1 * x_i$
 - Koeffizient β_1 kürzt sich je nach Ausprägung raus
 - Prädiktoren mit k Ausprägungen:**
 - Erstelle $k - 1$ Dummyvariablen
 - Andere ist Normalzustand
- Interaktionseffekte:
 - Synergieeffekte zwischen zwei oder mehreren Variablen
 - $\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \epsilon$
 - Auswirkung erkennen durch Umformung:
 - $\hat{y} = \beta_0 + \beta_2 x_2 + (\beta_1 + \beta_3 x_2) * x_1$
 - Erhöht man x_1 um eine Einheit erhöht sich \hat{y} um $\beta_1 + \beta_3 x_2$ Einheiten
 - x_1 moderiert x_2 und Vice versa
 - Signifikanz über p-value feststellen
 - Interaktion zwischen Quali und Quanti Variablen:
 - Kürzt sich komplett raus (wenn 0) oder ist *1 (wenn 1)

3 Klassifikation

- Grundlagen:

- Klassifikation ist Zuordnung von bedingten Wahrscheinlichkeiten anhand von Ausprägungen
- $P(Y = k | X = x)$
- Klasse mit höchster Wahrscheinlichkeit wird gewählt
- Bpsw: $Y = 1$ (Yes) und 0 (No)
 - Lineare Regression, die die Wahrscheinlichkeitsausgibt **funktioniert nicht!**
 - Reg.Gerade wird unter 0 fitten und auch nicht bis 1
- Funktion finden, die $0 \leq p(x) \leq 1$ für alle X
- Logistic Regression:**
 - $p(x) = \frac{e^{\beta_0 + \beta_1 * x}}{1 + e^{\beta_0 + \beta_1 * x}}$
 - $0 \leq p(x) \leq 1$, da immer $e^x \geq 0$ und $\frac{x}{1+x} \leq 1$
 - Odds:
 - $\frac{p(x)}{1-p(x)} = e^{\beta_0 + \beta_1 * x}$
 - $0 \leq odds \leq \infty$
 - Möglichkeit Wahrscheinlichkeit anzugeben:
 - Odds = $\frac{4}{3}$ -> "Siegchancen stehen 4 zu 3"
 - Umrechnung:
 - $p = \frac{odds}{1+odds} = \frac{e^{logit}}{1+e^{logit}}$
 - $odds = \frac{p}{1-p} = e^{logit}$
 - Logits:
 - $log(\frac{p(x)}{1-p(x)}) = \beta_0 + \beta_1 * X$
 - $-\infty \leq logits \leq \infty$
 - Logits hängen Linear von X ab
- Schätzung der Koeffizienten**
 - Schätzung von β_0 und β_1 über Maximum-Likelihood
 - $l(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) * \prod_{i: y_i=0} (1 - p(x_i))$
 - Funktion wird maximiert = da wo Likelihood am größten ist, sind Parameter am besten
- Validierung:**
 - Gleiche Werte/ Tests, wie bei lineare Regression
- Confounding:**
 - Zusammenhang zwischen zwei Prädiktoren
 - Trugschluss, wenn man nur einzelne Variable in Abhängigkeit zu Y betrachtet
 - In der Gesamtmasse wird es dann gut
 - Confounder beeinflusst gleichzeitig Zielgröße und anderen Prädiktor

4 Resampling

- Grundlagen:
 - TestError wird mit ungesehenen Daten berechnet.
 - Meist aber keine vorhanden -> TestError muss über Trainingsdaten geschätzt werden
 - Verfahren für Regression/Klassifikation anwendbar
- Einfache Validierung:**

- Teile Trainingsdaten in zwei gleiche große Mengen auf
- Menge1: für Training / Menge2: für Testing
- MSE variiert stark in Abhängigkeit der Trainingsmenge
- Modelle sollten möglichst mit hoher Trainingsmenge trainiert werden
- Hoher Bias, geringe Varianz
- **LeaveOneOut Validierung:**
 - n-Modelle werden mit n-1 Datensätze trainiert
 - Letzter Datensatz ist Testdatensatz
 - Durchschnitt aller MSEs ist finaler Wert
 - $CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i$
 - Vorteil: Größere Trainingsmenge
 - Nachteil: Hoher Rechenaufwand für n Modelle, größere Varianz als bei einfacher Val, durch Autokorrelation
 - geringer Bias, hohe Varianz
- **k-fold Validierung**
 - Teile Datensatz in k gleich große Mengen (5, 10..)
 - Trainiere k Modelle, wobei immer eine Teilmenge als Test genutzt wird
 - $CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i$
 - geringere Streuung des MSEs
 - Guter Kompromiss zwischen Rechenaufwand und guter Abschätzung
- Für Klassifikation wird der Anteil falsch klassifizierter Objekte genommen!

5 Modellauswahl

- p (# Prädiktoren), n (# Beobachtungen)
- Steigende Varianz und sinkender Prognosegüte, wenn p -> n
- Hohe Anzahl an Prädiktoren: Steigende Wahrscheinlichkeit von Multikollinearität (Abhängige Prädiktoren) und unnötige Komplexität
- Wenn $p \geq n$, ist Methode der kleinsten Quadrate gar nicht möglich
- **Best Subset Selection:**
 - Berechne alle Modelle mit k Parametern (Speicher das beste (Min. RSS oder Max. R^2))
 - Berechne für k = 0, 1, 2 .. x alle besten Modelle
 - Wähle beste aus Besten aus (siehe unten)
 - Hoher Rechenaufwand (2^p Modelle), Gefahr von Overfitting, findet optimales Modell
- **Forward Stepwise Selection:**
 - Berechne bestes Modell mit 0 Prädiktoren, dann mit 1, etc.

- Wähle für k immer das beste Modell und gehe von dort aus weiter
- Wähle beste aus Besten aus
- Weniger Rechenaufwand (p^2 Modelle), Overfitting unwahrscheinlich, findet nur lokales Optimum
- **Backward Stepwise Selection:**
 - Wie Forward Stepwise Selection nur rückwärts
 - Starte mit Modell mit k Prädiktoren und nimm immer den schlechtesten Weg
 - Wähle beste aus Besten aus
 - Weniger Rechenaufwand (p^2 Modelle), Overfitting unwahrscheinlich, findet nur lokales Optimum
- **Bestes Modell?**
 - R^2 und RSS ist nicht aussagekräftig, da es mit steigender Anzahl an Prädiktoren besser wird.
 - Testfehler indirekt messbar durch (C_p, AIC, BIC und R_{adj}^2) oder direkt durch Kreuzvalidierung
 - Anwendbar bei linearen Modellen
 - $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$
 - n: Anzahl der Beobachtungen, d: Anzahl der Prädiktoren
 - $\sigma^2 = Var(\epsilon) = \frac{1}{n-p-1} * RSS$
 - Mallows $C_p = \frac{1}{n} (RSS + 2d\sigma^2)$
 - $AIC = \frac{1}{n\sigma^2} (RSS + 2d\sigma^2)$ (Proportional zu C_p)
 - $BIC = \frac{1}{n\sigma^2} (RSS + \ln(n)d\sigma^2)$ (Höheres Gewicht auf Strafterm für viel Prädiktoren)
 - $R_a^2 = R^2 - \frac{p}{n-p-1} (1 - R^2)$ kann bei Hinzunahme einer Variable auch kleiner und oder negativ werden

6 R - Hilfe

- **Grundlagen:**
 - `set.seed(X)` Setzt Seed für random Number Generator
 - `c(1,2,3,4)` Vektor mit Zahlen 1-4
 - `rep(1:10,100)` Erzeugt Vektor mit zahlen 1-10, 100 mal
 - `rnorm(100)` Erzeugt Vektor mit 100 normalverteilten Werten
 - `runif(X,a,b)` Erzeugt X Zufallszahlen zwischen a und b
 - `df[2,3]` Greift auf Element der 2.Reihe und 3.Spalte des DFs zu
 - `df[, -3]` Entfernt 3. Spalte
 - `head()` Zeigt erste X Zeilen von DF an
 - `summary()` gibt Zusammenfassung von Modellen (DF, Modelle etc.)

- `table(X,Y)` gibt Tabelle bzw. Konfusionsmatrix aus
- `nrow(X)` gibt Anzahl der Zeilen in X
- `sample(n,n/2)` gibt 50% Subsetvektor
- `is.na(X)` findet/zählt null Values
- `na.omit(X)` entfernt null Values
- `var(X), mean(X)` Varianz und Durchschnitt von X
- **Modelle:**
 - `lm(A B + poly(C,2) + BC, data = ..., subset =)` Lineare Regression für A mit Interaktivität von BC und C mit Exponent 2
 - `glm(A B + C, data = ..., family = binomial, subset =)` Logistic Regression Modell
 - `predict(Modell, DataFrame, interval =, type =)`
 - * DF: `data.frame(x1 = c(2), x2 = c(3))`
 - * `interval` Konfidenzintervall(confidence), Prognoseintervall(prediction)
 - * `type` Wahrscheinlichkeit(response), Logits(ohne Angabe)
 - `coef()` Zeigt Koeffizienten des Modells
 - `confint()` Zeigt Konfidenzintervalle für Koeff.
 - `chisq.test(X,Y)` Macht ChiquadratTest auf Unabhängigkeit von X und Y (H_0 : Merkmale sind unabhängig)
- **Validierung:**
 - `mean((Auto$mpg - predict(lm.fit2, Auto))[-train]^2)` Berechnet die mittlere quadratische Abweichung
 - aus dem `boot` package
 - `cv.glm(Data, Modell)$delta[1]` LeaveOneOut (`$delta[1]` liefert nur ersten Wert also MSE)
 - `cv.glm(Data, Modell, k = X)$delta[1]` k-fold mit k Folds
 - `regsubsets(Y, data =, nvmax =, method =)` Subset-Selection (nvmax = Anzahl Attribute, methode= forward/backward/none)
- **Plots:**
 - `par(mfrow = c(2,2))` Zeigt 2x2 Matrix mit Plots
 - `pairs()` Zeigt Pärchenplott aller quantitativer Variablen
 - `plot(x,y,xlab =, ylab =)` Zeigt X/Y Plot zweier Variablen mit Achsenbeschriftung
 - `plot(modell)` Zeigt Plots zu Residuen etc.
 - `hist()` Zeigt Histogramm
 - `points()` Erzeugt Punkt im Plot
 - `abline(Modell,col = "red")` Zeigt Regressionslinie
 - `qplot()` aus `ggplot2` für quickplot