


1 Grundlagen

- Grundlagen
 - $Y = f(x) + \epsilon$
 - Y = Zielgröße, $f()$ = unbekanntes/wahres Modell, X = Prädiktoren, ϵ Nicht reduzierbarer Fehler
 - $\hat{Y} = \hat{f}(X) + \epsilon$
 - \hat{Y} = Schätzung der Zielgröße, \hat{f} = Schätzung des Modells
 - Ziel: Möglichst genaue Schätzung finden
- Ziel:
 - Prediction (Vorhersage von Werten)
 - Inference (Ursachenanalyse, wie wirken sich Änderungen aus)
- Bias-Variance Tradeoff
 - Bias: Fähigkeit des Modells die eigentliche Beziehung der Daten abzubilden
 - Variance: Fähigkeit des Modells auf anderen Subsets gleich gute Modelle zu erzeugen
 - TrainingsError: Wird immer kleiner, da Modell sich immer besser anpasst
 - TestError: Wird erst kleiner, steigt dann aber wieder (Overfitting)
 - Nichtreduzierbarer Error: Bleibt immer gleich (Messfehler etc.)



2 Regression

- Modellgüte:
 - Schätzung der Parameter β_0 und β_1 über kleinste Quadrate
 - * $\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) * (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$
 - * $\beta_0 = \bar{y} - \beta_1 \bar{x}$
 - * Erwartungstreue: $E(\hat{\beta}_0) = \beta_0$ und $E(\hat{\beta}_1) = \beta_1$
 - $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$

- $RSE = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$ (Zielgröße weicht im Durchschnitt RSE Einheiten von der Regressionsgeraden ab)
- $R^2 = 1 - \frac{RSS}{TSS}$, je größer desto besser $0 \leq R^2 \leq 1$ (Var(Zielwert) wird durch $R^2\%$ der Prädiktoren erklärt)
- $R_{adj}^2 = 1 - \frac{(1-R^2)(N-1)}{N-p-1}$ Adjustiert mit Anzahl der Prädiktoren
- Standardfehler und Intervalle
 - * $Var(\epsilon) = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
 - * $(SE(\hat{\beta}_0))^2 = Var(\epsilon) * (\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2})$
 - * $(SE(\hat{\beta}_1))^2 = \frac{Var(\epsilon)}{\sum_{i=1}^n (x_i - \bar{x})^2}$
 - * Intervallschätzung: $[\hat{\beta}_1 - 2 * SE(\hat{\beta}_1), \hat{\beta}_1 + 2 * SE(\hat{\beta}_1)]$
 - * Interpret: Aus 100 Proben liegt β_1 in 95 Fällen im Intervall
 - * 95%-Konfidenzintervall: bezieht sich auf den durchschnittlichen Y Wert
 - * 95%-Prognoseintervall: bezieht sich auf den konkreten Wert Y von Ausgangswerten $X_1 \dots$
- t-Test
 - * $H_0 : \beta_0 = 0; H_1 : \beta_1 \neq 0$
 - * X_1 Hat keinen Einfluss auf Y
 - * $t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$
 - * Einfach den p-Wert ablesen, wenn < als bspw. 0.05 dann H_0 verwerfen
- F-Test
 - * $H_0 : \beta_0 = \beta_1 = \dots = 0$
 - * Alle Prädiktoren haben keinen Einfluss auf Y
- Qualitative Prädiktoren:
 - **Prädiktoren mit 2 Ausprägungen:**
 - DummyVariable aka 0(No) oder 1 (Yes)
 - **Achte auf Normalausprägung von R**
 - $\hat{y} = \beta_0 + \beta_1 * x_i$
 - Koeffizient β_1 kürzt sich je nach Ausprägung raus
 - **Prädiktoren mit k Ausprägungen:**
 - Erstelle $k - 1$ Dummyvariablen
 - Andere ist Normalzustand
- Interaktionseffekte:
 - Synergieeffekte zwischen zwei oder mehreren Variablen
 - $\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \epsilon$
 - Auswirkung erkennen durch Umformung:
 - $\hat{y} = \beta_0 + \beta_2 x_2 + (\beta_1 + \beta_3 x_2) * x_1$
 - Erhöht man x_1 um eine Einheit erhöht sich \hat{y} um $\beta_1 + \beta_3 x_2$ Einheiten
 - x_1 moderiert x_2 und Vice versa

3 Klassifikation

- **Grundlagen:**
 - Klassifikation ist Zuordnung von bedingten Wahrscheinlichkeiten anhand von Ausprägungen
 - $P(Y = k | X = x)$
 - Klasse mit höchster Wahrscheinlichkeit wird gewählt
 - Bpsw: $Y = 1$ (Yes) und 0 (No)
 - * Lineare Regression, die die Wahrscheinlichkeitsausgabe **funktioniert nicht!**
 - * Reg. Gerade wird unter 0 fitten und auch nicht bis 1
 - Funktion finden, die $0 \leq p(x) \leq 1$ für alle X
- **Logistic Regression:**
 - $p(x) = \frac{e^{\beta_0 + \beta_1 * X}}{1 + e^{\beta_0 + \beta_1 * X}}$
 - $0 \leq p(x) \leq 1$, da immer $e^x \geq 0$ und $\frac{X}{1+X} \leq 1$
 - Odds:
 - * $\frac{p(x)}{1-p(x)} = e^{\beta_0 + \beta_1 * X}$
 - * $0 \leq odds \leq \infty$
 - * Möglichkeit Wahrscheinlichkeit anzugeben:
 - * Odds = $\frac{4}{3}$ -> "Siegchancen stehen 4 zu 3"
 - * Umrechnung:
 - * $p = \frac{odds}{1+odds} = \frac{e^{logit}}{1+e^{logit}}$
 - * $odds = \frac{p}{1-p} = e^{logit}$
 - Logits:
 - * $log(\frac{p(x)}{1-p(x)}) = \beta_0 + \beta_1 * X$
 - * $-\infty \leq logits \leq \infty$
 - * Logits hängen Linear von X ab
- **Schätzung der Koeffizienten**
 - Schätzung von β_0 und β_1 über Maximum-Likelihood
 - $l(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) * \prod_{i: y_i=0} (1 - p(x_i))$
 - Funktion wird maximiert = da wo Likelihood am größten ist, sind Parameter am besten
- **Validierung:**
 - Gleiche Werte/ Tests, wie bei lineare Regression
- **Confounding:**
 - Zusammenhang zwischen zwei Prädiktoren
 - Confounder beeinflusst gleichzeitig Zielgröße und anderen Prädiktor
 - **Hier fehlt's**

4 Resampling

• Grundlagen:

- TestError wird mit ungesehenen Daten berechnet.
- Meist aber keine vorhanden -> TestError muss über Trainingsdaten geschätzt werden
- Verfahren für Regression/Klassifikation anwendbar

• Einfache Validierung:

- Teile Trainingsdaten in zwei gleiche große Mengen auf
- Menge1: für Training / Menge2: für Testing
- MSE variiert stark in Abhängigkeit der Trainingsmenge
- Modelle sollten möglichst mit hoher Trainingsmenge trainiert werden
- Hoher Bias, geringe Varianz

• LeaveOneOut Validierung:

- n-Modelle werden mit n-1 Datensätze trainiert
- Letzter Datensatz ist Testdatensatz
- Durchschnitt aller MSEs ist finaler Wert
- $CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i$
- Vorteil: Größere Trainingsmenge
- Nachteil: Hoher Rechenaufwand für n Modelle, größere Varianz als bei einfacher Val, durch Autokorrelation
- geringer Bias, hohe Varianz

• k-fold Validierung

- Teile Datensatz in k gleich große Mengen (5, 10..)
- Trainiere k Modelle, wobei immer eine Teilmenge als Test

genutzt wird

- $CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i$
 - geringere Streuung des MSEs
 - Guter Kompromiss zwischen Rechenaufwand und guter Abschätzung
- Für Klassifikation wird der Anteil falsch klassifizierter Objekte genommen!

5 Modellauswahl

6 R - Hilfe

• Grundlagen:

- *set.seed(X)* Setzt Seed für random Number Generator
- *c(1,2,3,4)* Vektor mit Zahlen 1-4
- *df[2,3]* Greift auf Element der 2.Reihe und 3.Spalte des DFs zu
- *df[, -3]* Entfernt 3. Spalte
- *head()* Zeigt erste X Zeilen von DF an
- *summary()* gibt Zusammenfassung von Modellen (DF, Modelle etc.)
- *table(X, Y)* gibt Tabelle bzw. Konfusionsmatrix aus
- *nrow(X)* gibt Anzahl der Zeilen in X
- *sample(n, n/2)* gibt 50% Subsetvektor

• Modelle:

- *lm(A B + poly(C,2) + BC, data = ..., subset =)* Lineare Regression für A mit Interaktivität von BC und C mit Exponent 2

- *glm(A B + C, data = ..., family = binomial, subset =)* Logistic Regression Modell
- *predict(Modell, DataFrame, interval =, type =)*
 - * *DF: data.frame(x1 = c(2), x2 = c(3))*
 - * *interval* Konfidenzintervall(confidence), Prognoseintervall(prediction)
 - * *type* Wahrscheinlichkeit(response), Loggits(ohne Angabe)
- *coef()* Zeigt Koeffizienten des Modells
- *confint()* Zeigt Konfidenzintervalle für Koeff.
- *chisq.test(X, Y)* Macht ChiquadratTest auf Unabhängigkeit von X und Y (H_0 : Merkmale sind unabhängig)

• Validierung:

- *mean((Auto\$mpg - predict(lm.fit2, Auto))[-train]²)* Berechnet die mittlere quadratische Abweichung
- aus dem *boot* package
- *cv.glm(Data, Modell)\$delta[1]* LeaveOneOut (*\$delta[1]* liefert nur ersten Wert also MSE)
- *cv.glm(Data, Modell, k = X)\$delta[1]* k-fold mit k Folds

• Plots:

- *pairs()* Zeigt Pärchenplott aller quantitativer Variablen
- *plot()* Zeigt X/Y Plot zweier Variablen
- *abline(Modell, col = "red")* Zeigt Regressionslinie
- *qplot()* aus *ggplot2* für quickplot